

InsurMinds_PROTETOR — Relatório Técnico

Plataforma inteligente para análise e comparação de apólices D&O

Projeto Final · I2A2 — Instituto de Inteligência Artificial Aplicada · Outubro de 2026

Grupo **Gp_Protetor** — Ricardo Croce (Chefe), José Carlos dos Passos, Renato Sant Anna, Tiago Del Rio e Juliano Silva Ignacio.

Repositório: https://github.com/Georastreador/InsurMinds_Projeto_Final_PROTETOR

1. Resumo

O InsurMinds_PROTETOR é um MVP que recebe duas apólices ou condições contratuais de seguro D&O (Directors & Officers) em PDF ou imagem, extrai e estrutura seu conteúdo com IA generativa, compara coberturas, exclusões, franquias, limites e cláusulas, e apresenta ao analista uma síntese executiva em que cada diferença aponta a página de origem. O sistema não recomenda qual apólice contratar: descreve diferenças documentais e deixa a decisão ao especialista.

A solução é um **workflow orquestrado**: um **Harness** (orquestrador com máquina de estados) decide a sequência e controla seis etapas especializadas (A1 a A6) e uma etapa de consulta sob demanda. As etapas não decidem o fluxo; essa escolha privilegia previsibilidade e auditabilidade. Usa a API da OpenAI em seis pontos: OCR multimodal, extração estruturada, julgamento semântico da comparação, redação da síntese, respostas de consulta e classificador do guardrail anti-veredito.

No conjunto de avaliação principal (condições gerais D&O da Chubb e da Sompó, com anotação humana), três execuções LIVE reavaliadas em conjunto mostram: extração correta de todos os campos com valor anotado; evidência na página anotada em 100% dos casos e 98–100% dos trechos citados conferidos no texto da página; e acurácia de comparação de 0,77 em média (pior caso 0,70) no gabarito original v1.0, abaixo da meta de 0,90. No gabarito revisado v1.1, a média é 0,97. Uma análise completa de dois documentos de 50 a 70 páginas leva cerca de 3 minutos.

2. Problema e objetivos

Apólices de seguro são documentos longos e jurídicos. Em D&O, cada seguradora organiza coberturas, extensões, exclusões e cláusulas de forma própria, com nomes diferentes para conceitos equivalentes, e muitos valores (limites, franquias, vigência) ficam na Especificação da Apólice, não nas condições gerais. A comparação manual exige horas de leitura especializada.

Objetivos do MVP:

1. Receber documentos em PDF ou imagem e extrair o conteúdo automaticamente.
2. Estruturar a informação num formato comum e armazená-la.
3. Comparar ao menos duas apólices, identificando diferenças materiais.
4. Apresentar as principais diferenças com rastreabilidade Claim → Evidence (página e trecho).
5. Permitir consulta ao acervo de documentos processados.
6. Usar IA generativa de forma controlada: sem inventar fatos e sem emitir veredito.

3. Arquitetura da solução

A solução tem quatro camadas:

1. **Orquestração (Harness).** O `Orchestrator` mantém uma máquina de estados explícita (`CREATED` → `INGESTING` → `EXTRACTING` → `ANALYZING` → `VALIDATING` → `READY_TO_COMPARE` → `COMPARING` → `SYNTHESIZING` → `COMPLETED`, com `RETRYING`, `WARNING`, `REVIEW_REQUIRED` e `FAILED` como estados de exceção) e rejeita transições não previstas. O `CompleteMVPPipeline` executa os dois documentos sob um único `run_id` (A e B percorrem A1→A4 em paralelo; toda mudança de estado passa pelo `Orchestrator`), verifica cada trecho de evidência no texto da página, avalia o escopo (ramo e natureza do

- documento), emite o progresso para a interface, registra cada evento no trace e persiste os artefatos.
- Agentes especializados (A1 a A6 e Consulta).** Cada agente recebe uma entrada tipada e devolve uma saída tipada; nenhum decide a sequência, repete a si mesmo ou encerra a execução. Quatro deles usam IA generativa (A2 no OCR, A3, A5 e A6), sempre atrás de um contrato Pydantic e de guardrails no código.
 - Infraestrutura.** A API da OpenAI é acessada por adaptadores que implementam contratos neutros de provedor (StructuredLLMClient, SemanticComparator, SynthesisWriter, OCREngine), o que permite testar tudo com implementações simuladas e trocar o modelo por configuração. O SQLite guarda runs, documentos, textos, apólices, comparações e relatórios, e alimenta a Consulta.
 - Interface.** O Streamlit separa a experiência do analista (Resumo, Comparação, Evidências, Apólices, Consulta) da observabilidade técnica (Auditoria da IA), mostra estimativa de tempo e progresso por agente e reabre runs gravados no modo apresentação.




Figura 1 — Arquitetura do InsurMinds_PROTETOR. Em lilás, os componentes que usam IA generativa; em cinza, os determinísticos. A seta tracejada laranja é o ciclo de nova tentativa controlado pelo Harness.

Contrato	Papel
PolicySchema	Representação canônica de um documento: identificação, vigência, limites, franquias, Sides A/B/C, coberturas, exclusões, cláusulas, extensões, ramo, natureza do documento e evidências
ComparisonResult	Um item por campo ou conceito comparado, com valores de A e B, evidência de cada lado, estado controlado, confiança e critério
InsurMindsState	Estado compartilhado do run: documentos, textos, apólices, comparação, síntese, métricas, avisos e trace
Taxonomia D&O	18 conceitos de cobertura, 17 de exclusão e 23 de cláusula (estrutura SUSEP), usados para parear itens entre seguradoras

Princípio central: o Harness controla o sistema; os agentes executam funções delimitadas. Isso torna o comportamento previsível, auditável e testável sem chamadas de API.

4. Fluxo completo de processamento

1. **Upload:** o analista envia A e B. A interface mostra páginas, tamanho, páginas digitalizadas e o tempo estimado.
2. **A1 Intake:** valida existência, tamanho e formato (PDF, PNG, JPG) e registra metadados.
3. **A2 Extraction:** extrai o texto nativo por página com PyMuPDF e insere marcadores [[PÁGINA n]]. Páginas com imagem e sem camada de texto, e arquivos de imagem, passam por OCR multimodal com GPT, em lotes de 4 páginas, com transcrição literal.
4. **A3 Análise:** o LLM recebe o texto (até 300 mil caracteres; acima disso mantêm-se as primeiras páginas e as de maior densidade contratual, com aviso) e preenche o `PolicySchema` via Structured Outputs com JSON Schema estrito. Classifica ramo, natureza do documento e o conceito D&O de cada item.
5. **A4 Validação:** valida o candidato com Pydantic, normaliza datas brasileiras, rejeita anos implausíveis, remove "valores" que são apenas definições de papel e impede que a retroatividade seja registrada como prazo complementar. Se falhar, o Harness pede ao A3 nova tentativa com a lista de erros (até 2 retries).
6. **Verificação de evidência:** cada trecho citado pelo A3 é procurado no texto da página citada; trechos em outra página ou não localizados são sinalizados e reduzem a confiança do item na comparação.
7. **Escopo:** o Harness confirma o ramo (LLM com reforço determinístico) e marca o run como "D&O validado" ou "genérico".
8. **A5 Comparação:** compara campos simples, limites e Sides A/B/C; pareia coberturas, exclusões e cláusulas pelo conceito da taxonomia; pede ao LLM o pareamento de itens órfãos (sempre enviados à revisão humana) e o julgamento do conteúdo dos pares (igual, diferente ou revisão humana).
9. **A6 Síntese:** o LLM redige a visão geral e as principais diferenças referindo-se apenas a itens do A5 por identificador; status e páginas são anexados pelo código.
10. **Persistência e apresentação:** tudo é gravado no SQLite e exibido em Resumo, Comparação, Evidências, Apólices e Auditoria, com exportação em MD, PDF, CSV e JSON.

5. Agentes desenvolvidos

Agente	Entrada	Saída	Técnica	Principais salvaguardas
A1 Intake	Arquivo	Metadados	Regras	Formato, tamanho, existência
A2 Extraction	Metadados	Texto por página	PyMuPDF + OCR GPT (Tesseract opcional)	OCR só onde falta texto; limite de 40 páginas com aviso; transcrição literal
A3 Análise D&O	Texto	Candidato <code>PolicySchema</code>	LLM com Structured Outputs	Schema estrito; "não inventar"; página em cada evidência
A4 Validação	Candidato	<code>PolicySchema</code> válido	Pydantic + regras	Retry com feedback; datas plausíveis; papéis ≠ valores
A5 Comparação	2 apólices	<code>ComparisonResult</code>	Taxonomia + LLM juiz	Estados controlados; confiança mínima configurável; pares órfãos e evidência não confirmada sinalizados
A6 Síntese	<code>ComparisonResult</code>	Relatório	LLM redator	Só itens existentes; guardrail anti-veredito em 2 camadas; alternativa determinística
Consulta	Pergunta + acervo	Resposta citada	Recuperação de páginas + LLM	Só páginas enviadas podem ser citadas; sem veredito

6. Tecnologias utilizadas

Tecnologia	Versão testada	Papel na solução	Por que foi escolhida
Python	3.13 (requer 3.10+)	Linguagem de toda a solução	Ecossistema de IA e de documentos; usado ao longo do curso
OpenAI API — Responses API	SDK <code>openai</code> 2.54	OCR, extração, juiz semântico, síntese e consulta	Structured Outputs com JSON Schema estrito e entrada de imagem na mesma API e credencial
Modelo <code>gpt-5.6-luna</code>	configurável em <code>OPENAI_MODEL</code>	Modelo usado nos resultados deste relatório	Suporte a schema estrito e visão; troca por configuração, sem mudar código
Pydantic	2.13	Contratos (<code>PolicySchema</code> , <code>ComparisonResult</code> , estado) e validação do A4	Validação declarativa, mensagens de erro usadas como feedback no retry, geração do JSON Schema
PyMuPDF	1.28	Texto por página, detecção de páginas digitalizadas, renderização para OCR, PDF da síntese e do relatório	Rápido, sem dependências de sistema, lê e escreve PDF
Streamlit	1.64	Interface: upload, progresso, abas, downloads, consulta	Protótipo funcional em Python puro, adequado a um MVP demonstrável
SQLite	3.50 (embutido no Python)	Armazenamento estruturado e base da Consulta	Sem servidor, arquivo único, suficiente para o volume do MVP
pandas	2.3	Tabelas da interface e exportação CSV	Integração nativa com o Streamlit
Markdown	3.11	Conversão da síntese e do relatório para PDF	Leve; a síntese já é produzida em Markdown
python-dotenv	1.2	Leitura da chave e das configurações do <code>.env</code>	Mantém credenciais fora do código
pytest	9.1	145 testes automatizados sem chamadas de API	Padrão de mercado; permite testar agentes com dublês
Tesseract (opcional)	—	OCR offline, usado apenas se estiver instalado	Alternativa sem internet para o modo DEMO

7. Justificativa das decisões arquiteturais

- **Harness no controle, agentes especializados.** Separar coordenação de execução permite testar cada agente isoladamente, repetir etapas com segurança e registrar um trace completo, em vez de depender de agentes que decidem a própria sequência.
- **Structured Outputs com schema estrito, validação local no A4.** O schema estrito força o formato no provedor; o A4 continua sendo a autoridade de validação, o que permite retries com feedback. No primeiro teste LIVE, sem schema estrito, o modelo devolveu 22 erros de estrutura e o run falhou; com a mudança, os runs passaram a ser aceitos na primeira tentativa, e as poucas rejeições (ex.: "5% do LMI" num campo numérico) foram corrigidas na segunda.
- **Marcadores de página no texto.** São a base do Claim → Evidence: o LLM cita a página que viu, e a interface a exibe ao lado de cada diferença.
- **Taxonomia D&O + juiz semântico.** Comparar pelo nome devolvido pelo LLM falhava entre seguradoras (a Chubb veio em inglês, a Somo em português): a acurácia da comparação era 0,50. Pareando por conceito e deixando o LLM julgar apenas o conteúdo dos pares, chegou a 0,80.
- **Síntese generativa limitada por identificadores.** A primeira síntese determinística tinha 87 mil caracteres. A versão generativa tem cerca de 5 mil, mas o modelo só pode referir itens existentes, e páginas e status são anexados pelo código.
- **OCR com GPT em vez de Tesseract.** Não exige instalação no sistema, lida melhor com tabelas e usa a mesma credencial; o Tesseract permanece como alternativa offline opcional.

- **Escopo D&O com análise genérica sinalizada.** O enunciado foca D&O; documentos de outros ramos são analisados com os campos gerais e marcados como fora do escopo validado, em vez de serem tratados silenciosamente como D&O.
- **Verificação determinística de evidência.** O trecho citado é escrito pelo LLM; conferi-lo no texto da página custa milissegundos e transforma Claim → Evidence de promessa em garantia verificável.
- **Guardrail anti-veredito em duas camadas.** A lista de 9 palavras da v1.2 deixava passar "Recomenda-se contratar A". Padrões ampliados (sem bloquear comparações factuais) + classificador LLM barato cobrem paráfrases; uma suíte adversarial fixa o comportamento.
- **SQLite e Streamlit.** Simples de instalar e suficientes para um MVP demonstrável, conforme a orientação de preferir soluções simples e compreensíveis.

8. Avaliação e resultados

8.1 Dataset 1 — Golden D&O (Chubb × Somo)

Dois documentos oficiais de condições gerais D&O (70 e 49 páginas) com anotação humana de campos, páginas e trechos, e uma comparação esperada de 10 itens. Os números abaixo são a **média e o pior caso de três execuções LIVE** com o A5 atual, reavaliadas offline (evaluation/aggregate_runs.py), e não a melhor execução.

Métrica	Chubb	Somo	Meta
EVAL-01 Validade do schema	1,00	1,00	—
EVAL-02 Campos anotados (média / pior)	0,97 / 0,92	1,00 / 1,00	≥ 0,80
EVAL-02 baseline: extrator que só devolve nulos	0,50	0,55	—
EVAL-02 só campos com valor esperado	1,00	1,00	—
EVAL-03 Página da evidência	1,00	1,00	≥ 0,80
Trechos conferidos na página (todas as referências)	0,99–1,00	0,98–1,00	—

Comparação (EVAL-04)	Média	Pior caso	Meta
Gabarito v1.0, 10 itens	0,77	0,70	≥ 0,90
Gabarito v1.0, 5 itens discriminantes	0,53	0,40	—
Gabarito v1.1, 10 itens	0,97	0,90	≥ 0,90

Metade dos campos do EVAL-02 e metade dos itens do EVAL-04 esperam "não identificado": medem o guardrail de não inventar, não a capacidade de extrair ou comparar. Por isso os subescores discriminantes são reportados em separado.

A revisão v1.1 alterou os dois itens em que o sistema divergia (exclusões ambiental e cibernética), após verificação no texto-fonte: a exclusão ambiental da Chubb tem recompra por cobertura adicional (p. 42 e 51–55), ausente na Somo, e a cibernética da Chubb limita-se à perda de dados (p. 65), enquanto a da Somo abrange ataques e malware (p. 17). Como a revisão foi feita depois de ver a saída, a v1.0 permanece a referência principal.

Calibração do juiz semântico. Nos 79 itens julgados, a confiança mínima foi 0,78 e a mediana 0,98; o corte de 0,7 nunca disparou. Os 15 itens com gabarito tinham confiança ≥ 0,95 e acerto de 0,53 (v1.0): a confiança autodeclarada não separa acertos de erros. Pares formados fora da taxonomia passaram a exigir revisão humana, e a calibração real depende de ampliar o gabarito (protocolo em evaluation/golden_dataset/ANNOTATION_PROTOCOL.md).

Erro encontrado fora do gabarito. No run de referência, a Somo teve a regra de retroatividade gravada como prazo complementar, e o A5 a comparou com o prazo complementar da Chubb, gerando uma "diferença" na síntese. O A4 da v1.3 corrige esse caso (teste em tests/test_v13_improvements.py); a medição LIVE das correções da v1.3 está pendente.

8.2 Dataset 3 — Robustez e OCR (execuções LIVE)

Cenário	Verificações	Tempo
Empresarial PME (254 páginas) × Residencial — limite de tamanho e ramos diferentes	8/8	3 min 05 s
Residencial × apólice sintética — limites e franquias em R\$ contra gabarito	19/19	2 min 17 s
Seguro Garantia × Vida — controle negativo de escopo	7/7	1 min 43 s
PDF só imagem × PDF nativo da mesma apólice — OCR	33/33	1 min 40 s
Imagem PNG × PDF nativo — OCR de imagem	aprovado	57 s

8.3 Dataset 2 — Estudo de caso de evolução temporal

- **PRODEMGE 2020 (contrato digitalizado, Ezze) × 2025 (Austral):** o OCR leu as 15 páginas em 1 min 28 s. O sistema identificou a troca de seguradora, o aumento do limite de R\$ 30 mi para R\$ 40 mi e o valor contratado (R\$ 74 mil para R\$ 35 mil), conferidos nos documentos.
- **Invepar DFP 2024 × ITR 2025 (demonstrações financeiras):** a síntese captou a mudança de seguradora do D&O (Allianz na tabela de 2024, Berkley em 2025), com páginas. O caso expôs limitações descritas na seção 9: unidade em milhares, várias apólices num mesmo documento e uma nota de rodapé que contradiz a tabela na própria DFP.

8.4 Testes automatizados

145 testes cobrem agentes, Harness (incluindo execução paralela e validade de todas as transições de estado), retries, guardrails (suíte adversarial anti-veredito, prompt injection, LGPD), verificação de evidência, taxonomia, OCR (com motor simulado), extração seccionada, exportação, consulta e avaliação, sem chamadas de API. A instalação limpa a partir do `requirements.txt` foi verificada.

9. Limitações conhecidas

- **Amostra de avaliação pequena:** 2 documentos anotados e 10 itens de comparação (5 discriminantes), contra cerca de 100 itens produzidos por execução. A revisão v1.1 do gabarito foi motivada por divergências apontadas pelo próprio sistema; por isso v1.0 é a referência e v1.1 é reportada ao lado.
- **Meta de comparação não atingida:** EVAL-04 v1.0 = 0,77 em média (meta 0,90).
- **Correções da v1.3 ainda não medidas em LIVE:** os números da seção 8 vêm de execuções da v1.2.
- **Variação entre execuções:** o LLM não é determinístico; a quantidade e a granularidade dos itens extraídos variam entre runs, o que afeta a contagem de itens exclusivos.
- **Condições gerais × apólice emitida:** o Golden Dataset não tem valores individualizados; limites e franquias em R\$ foram verificados na apólice sintética e nos contratos do estudo de caso.
- **Um documento, uma apólice:** o schema representa uma apólice por documento. Demonstrações financeiras que listam várias apólices geram campos inconsistentes entre documentos.
- **Unidades:** valores em "R\$ mil" são reconhecidos em aviso, mas não convertidos automaticamente.
- **Datas deduzidas:** quando o documento diz apenas "12 meses a partir da assinatura", o modelo pode calcular a vigência a partir da assinatura eletrônica; isso é sinalizado em aviso.
- **Normalização de texto:** diferenças de pontuação (hífen × travessão) podem marcar como "diferente" um mesmo nome.
- **Limites de tamanho:** acima de 300 mil caracteres, páginas de menor densidade contratual são omitidas (com aviso); o OCR lê até 40 páginas por documento.
- **OCR generativo:** pode repetir ou, em tese, completar trechos; a transcrição é instruída a ser literal e o método fica registrado no trace.

- **Modo DEMO:** o extrator heurístico serve apenas para demonstração offline.
- **Privacidade:** no modo LIVE, os documentos são enviados à API da OpenAI; CPF, e-mail e telefone são mascarados, mas imagens enviadas ao OCR não. O SQLite local não é criptografado.
- **Confiança do juiz não calibrada:** ver seção 8.1.

10. Possibilidades de evolução

1. Anotar o gabarito v2.0 (37 itens, anotação cega) e ampliar com os candidatos já catalogados (Fator, AXA, HDI); medir sempre média e pior caso.
2. Medir a extração seccionada (`OPENAI_EXTRACTION_MODE=sectioned`) contra a extração em chamada única.
3. Unir condições gerais e Especificação da mesma apólice numa única análise.
4. Suportar documentos com várias apólices (divulgações financeiras) e normalização de unidades.
5. Busca semântica com embeddings no acervo e comparação de mais de dois documentos.
6. Ciclo de feedback do especialista: correções humanas alimentando o gabarito e ajustes da taxonomia.
7. Modelos locais ou OCR dedicado (Azure Document Intelligence, Textract) para cenários com restrição de dados.
8. Integração contínua executando testes e avaliações a cada mudança.

11. Fontes dos documentos

- Chubb — Condições Contratuais D&O Capital Fechado, processo SUSEP 15414.900832/2017-90, versão 12/2025: <https://www.chubb.com/content/dam/chubb-sites/chubb-com/br-pt/condicoes-gerais/diretores-e-administradores/capital-fechado-processo-susep-15414-900832-2017-90-versao-a-partir-de-16-12-2025.pdf>
- Sompo — Condições Gerais RC D&O v1.5, processo SUSEP 15414.652408/2023-71, 11/2025: <https://sampo.com.br/produto/sampo-responsabilidade-civil-do>
- Invepar — Demonstrações contábeis de 31/12/2024 (DFP) e 31/12/2025, publicadas no site de relações com investidores.
- PRODEMGE — Contratos PS 907/2020 (Ezze Seguros) e PS 1037/2025 (Austral Seguradora), Sistema Eletrônico de Informações de Minas Gerais.
- Robustez: SUSEP (Automóvel), BB Seguros (Residencial), Porto Seguro (Viagem), Chubb (Empresarial PME), Banrisul/Icatu (Vida), Governo do RS (Seguro Garantia) e apólice sintética criada para o projeto.

Checksums SHA-256 e URLs completas: `datasets/SOURCES.md` e `datasets/stress_test/README_origem.md`.